

Spis treści

1	SocialPageRank	2
1.1	Opis	2
1.2	Wyniki algorytmu dla przykładowych danych	3
1.3	Implementacja	4
1.3.1	Baza danych	4
1.3.2	Tworzenie i mnożenie macierzy	5
1.4	Wyniki - czesciowe: TODO	5
1.4.1	Problemy : TODO	6
1.4.2	Przykładowe wyniki wyszukiwarki : TODO	6
2	Adapted PageRank	7
2.1	Opis	7
2.1.1	Algorytm FolkRank	8
2.1.2	Przykładowe wyniki	8
2.2	Implementacja	9
2.3	Wyniki	10
2.4	Porównanie algorytmu SocialPageRank i algorytmu Adapted PageRank : TODO	10
2.4.1	Porównanie na małym przykładzie	10
2.4.2	Porównanie w działającym systemie	10

Rozdział 1

SocialPageRank

1.1 Opis

SocialPageRank jest algorytmem wyliczającym statyczny ranking stron z perspektywy użytkownika sieci. Algorytm bazuje na obserwacji relacji między popularnymi stronami, tagami i aktywnymi użytkownikami. Popularne strony są dodawane przez aktywnych się użytkowników, które są opisywane popularnymi tagami. Aktywni się użytkownicy używają popularnych tagów dla popularnych stron. Popularne tagi używane są do annotacji popularnych stron przez ważnych użytkowników.

Bazując na powyższych założeniach algorytm propaguje i wzmacnia zależności między popularnymi tagami, użytkownikami i dokumentami.

Dane wejściowe:

N_T : ilość tagów

N_U : ilość użytkowników

N_D : ilość dokumentów

M_{DU} : macierz $N_D \times N_D$ asocjacyjna między dokumentami a użytkownikami

M_{UT} : macierz $N_U \times N_T$ asocjacyjna między użytkownikami a tagami

M_{TD} : macierz $N_T \times N_D$ asocjacyjna między tagami a dokumentami

P_0 : wektor, o długości N_D ,

Inicjalizacja

W komórce macierzy $M_{DU}(d_n, u_k)$ znajduje się wartość będąca ilością adnotacji przypisanych do dokumentu d_n przez użytkownika u_k . Podobnie dla pozostałych macierzy, elementy $M_{UT}(u_k, t_n)$ to ilość dokumentów opisanych tagiem t_n przez użytkownika u_k , elementy $M_{TD}(t_n, d_k)$: ile użytkowników dawało dokument d_k i oznaczyło go annotacją t_n .

Wektor P_0 zainicjalizowany został losowymi wartościami z przedziału $[0, 1]$. Jest on pierwszym przybliżeniem rank dokumentów.

repeat

$$U_i = M_{DU}^T * P_i$$

$$T_i = M_{UT}^T * U_i$$

$$P'_i = M_{TD}^T * T_i$$

$$T'_i = M_{TD} * P'_i$$

$$U'_i = M_{UT} * T'_i$$

$$P_{(i+1)} = M_{DU} * U'_i$$

until wartości wektora P_n nie zbiegną

Złożoność

Złożoność czasowa każdej iteracji wynosi $O(N_u * N_d + N_t * N_d + N_t * N_u)$.

1.2 Wyniki algorytmu dla przykładowych danych

W poniższej tabelce znajdują się dane, dla których zostało sprawdzone działanie algorytmu Social PageRank. Dane są nie duże i składają się z trzech różnych dokumentów, dwóch użytkowników i trzech tagów.

Strony www	użytkownicy	
	użytkownik 1	użytkownik 2
http://www.ted.com/	inspiration	
http://www.colourlovers.com/	design	inspiration
http://www.behance.net/	portfolio, design	portfolio, inspiration

Dla takich danych macierz $M_{d,u}$ mówiąca o zależności dokumentów z użytkownikami ma postać:

$$M_{d,u} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$$

Macierz użytkowników i tagów, $M_{u,t}$:

$$M_{u,t} = \begin{pmatrix} 1 & 1 & 1 \\ 2 & 0 & 1 \end{pmatrix}$$

Macierz tagów i dokumentów, $M_{t,d}$:

$$M_{t,d} = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{pmatrix}$$

wyniki:

Dla powyższych danych wyniki algorytmu zbiegają po czterech iteracjach z dokładnością $|P_3 - P_4| < 10^{-10}$. Wyniki zostały przedstawione w poniższej tabelce:

	Social PageRank
www.ted.com	0.2381373691295440
www.colourlovers.com	0.4343479235414989
www.behance.net	0.8686958470829979

Można zauważyć, że największy ranking ma strona behance.net która została dodana przez dwóch użytkowników i oznaczonych najpopularniejszymi tagami - 2 razy tagiem portfolio, użytym tylko dla tej strony, raz tagiem design, który użyty był 2 razy w powyższych danych i również raz tagiem inspiration, który jest najpopularniejszym tagiem, użytym w przykładzie aż 3 razy.

1.3 Implementacja

Algorytm pozwala na wcześniejsze wyliczenie rankingów dlatego został zaimplementowany jako osobny proces. Dodatkowo algorytm wymaga danych, które muszą być wyliczone i zapisane w bazie danych przed rozpoczęciem jego działania.

1.3.1 Baza danych

Poniżej znajduje się obrazek przedstawiający bazę danych ze zmianami wymaganymi dla sprawnego działania algorytmu. Dodatkowe tabele dodane zostały dla przyspieszenia generowania danych wejściowych. Dane w nich zawarte wyliczane są z danych wyliczane są z danych już istniejących w bazie danych.

TODO: OBRAZEK - BAZA DANYCH Z DODATKOWYMI TABELAMI I ZAZNACZONYMI UŻYWANYMI POLAMI W BAZIE DANYCH

Tabela DOKUMENT zawiera dodatkowo pole soc_page_rank służące do przechowywania wyników algorytmu. Tabele TAG_USR i TAG_DOC jak również pole w tabeli USERTAGDOC.how_much zawierają redundantne dane wykorzystywane do generowania macierzy. Pole USERTAGDOC.how_much zawiera informacje o ilości tagów użytych przez użytkownika do opisu dokumentu. TAG_USR zawiera relacje między użytkownikami i tagami, ilość annotowanych dokumentów przez tę parę znajduje się w polu how_much. Analogicznie TAG_DOC jest relacją między annotacjami a dokumentami z ilością ich wykorzystania.

1.3.2 Tworzenie i mnożenie macierzy

Algorytm wymaga w każdej iteracji wykorzystania sześć macierzy. Z powodu wielkości danych nie jesteśmy w stanie przechowywać ich wszystkich w pamięci. Dodatkowo biblioteka wykorzystana do mnożenia macierzy nakłada ograniczenia na ilość kolumn i wierszy w macierzach. Kolejnym problemem jest czas potrzebny na pobranie danych z bazy danych.

Z powodu tych ograniczeń macierze pobierane są do partiami do pamięci z bazy danych, przetwarzane i zapisywane są w struktury ułatwiające szybki do nich dostęp. Następnie, zapisywane są w plikach zawierające największe porcje danych mieszczące się jednocześnie w pamięci.

W każdej iteracji algorytm pobiera dane z dysku. Z tych danych tworzona jest macierz o maksymalnej możliwej ilości wierszy na które pozwala wykorzystana biblioteka. Każda z tych części jest osobno mnożona przez wektor. Wyniki następnie składane są w wektorze wynikowym, który przekazywany jest do kolejnego mnożenia macierzy

WYKRES POKAZUJĄCY PROCES TWORZENIA I MNOŻENIA CZĘŚCIOWEGO MACIERZY

Mimo, że wymagania pamięciowe sprawiają, że trzeba wykonać większą liczbę działań w czasie mnożenia, macierze generowane są dość rzadkie. Większość pól zawiera wartość 0, co przyspiesza mnożenie macierzy i wektorów.

TODO: ilość wykorzystanych plików przy prawdziwych danych (1 mln)

TODO: ilość mnożeń

TODO: wykorzystana biblioteka: cern.colt

1.4 Wyniki - czesciowe: TODO

// wyniki dla danych 66 000 dokumentów - TODO - wyniki dla dużych danych

Strona <http://www.pythonchallenge.com/> jest jedną ze stron z największym wynikiem socialpagerank (0.00301). Dodane jest przez 785 różnych użytkowników. Zostało użyte do tego 209 unikalnych tagów. Najpopularniejsze tagi, w kolejności od najczęściej użytego to python, programming, challage i puzzle.

Jedną ze stron o najniższym rankingu jest np: <http://djangosnippets.org/snippets/1314/>. Strona ta zawiera specyficzne rozszerzenie dla frameworku django. Można się spodziewać że nie będzie to popularna witryna. Została ona dodana przez jednego użytkownika i opisana siedmioma anotcjami.

Strony które uzyskały ranking 0 to strony które nie zostały opisane żadnymi tagami przez użytkowników.

1.4.1 Problemy : TODO

Potencjalne problemy zauważone na mniejszej ilości danych: algorytm jest podatny na cykle które mogą zostać stworzone przez dużą ilość wygenerowanych użytkowników.

1.4.2 Przykładowe wyniki wyszukiwarki : TODO

TODO: OPISAC POZNIEJ, PO ZAIMPLEMENTOWANIU WYSZUKIWANIA UZYWAJACEGO SOCIALPAGERANK

Rozdział 2

Adapted PageRank

2.1 Opis

Algorytm Adapted Page Rank jest zainspirowany algorytmem PageRank. Ideą za algorytm PageRank jest pomysł, że strona jest ważna jeśli dużo innych stron ma odnośniki wskazujące na tą stronę i te strony są również ważne.

Ponieważ algorytm page rank nie może być bezpośrednio zastosowany do zebranych danych autorzy algorytmu adapted page rank zmienili strukturę danych na nieskierowany graf trydzienny $G_f = (V, E)$.

Proces tworzenia grafu G_f :

1) zbiór wierzchołków V powstaje z sumy rozłącznej zbioru użytkowników, tagów, i dokumentów: $V = U \cup T \cup R$

2) wszystkie wystąpienia łącznie tagów, użytkowników, dokumentów stają się krawędziami grafu G_f : $E = \{\{u, t\}, \{t, r\}, \{r, u\} | (u, t, r) \in Y\}$. Wagi tych krawędzi są przydzielane w następujący sposób: każda krawędź $\{u, t\}$ ma wagę $|\{r \in R : (u, t, r) \in Y\}|$, czyli jest to ilość dokumentów, którym użytkownik u nadał anotację t . Analogicznie dla krawędzi $\{t, r\}$: $waga = |\{u \in U : \{(u, t, r) \in Y\}|$ i krawędzi $\{r, u\}$, gdzie $waga = |\{t \in T : \{(u, t, r) \in Y\}|$.

dane wejściowe:

A – prawo stochastyczna macierz sąsiedztwa grafu G_f

p – wektor preferencji

w – losowo zainicjalizowany wektor

α, β, γ – stałe, gdzie: $\alpha, \beta, \gamma \in [0, 1]$ i $\alpha + \beta + \gamma = 1$

do:

$w = \alpha * w + \beta * A * w + \gamma * p$

while: do czasu kiedy wartości wektora w zbiegają się.

wynikiem algorytmu jest wektor w .

Dane zostały uzyskane dla parametrów: $\alpha = 0.35, \beta = 0.65, \gamma = 0$ i pochodzą z pracy (cytat! / połączenie z bibliografią).

W algorytmie adapted page rank wektor preferencji i $p = 1$.

2.1.1 Algorytm FolkRank

Algorytm FolkRank jest wersją algorytmu adapted page rank, który daje różne wyniki w zależności od tematu. Temat tej jest ustalany w wektorze preferencji p . Wektor preferencji może być ustalony na wybrany zbiór tagów, użytkowników, dokumentów, albo na pojedynczy element. Wybrany temat będzie propagowany na reszcie dokumentów, tagów i użytkowników. Można dzięki temu, ustalając wagę na zapytanie albo konto użytkownika systemu uzyskać wyniki bardziej zbliżone do zainteresowań danego użytkownika.

Algorytm FolkRank może pomóc w analizie zbioru danych, albo w systemach nie działających w czasie rzeczywistym, ale nie jest użyteczny w zaprezentowanym systemie. Nie jest możliwy do wykorzystania z powodu długiego czasu obliczania wag dokumentów.

2.1.2 Przykładowe wyniki

Działanie algorytmu dla danych złożonych z 3 różnych dokumentów, 2 użytkowników i 3 tagów.

Strony www	użytkownicy	
	użytkownik 1	użytkownik 2
http://www.ted.com/	inspiration	
http://www.colourlovers.com/	design	inspiration
http://www.behance.net/	portfolio, design	portfolio, inspiration

macierz asocjacyjna powstała z powyższych danych ma wymiary 8×8 i wygląda:

$$G_f = \begin{pmatrix} 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 & 0 \\ 0 & 0 & 0 & 2 & 2 & 1 & 1 & 2 \\ 1 & 1 & 2 & 0 & 0 & 1 & 2 & 1 \\ 0 & 1 & 2 & 0 & 0 & 2 & 0 & 1 \\ 1 & 1 & 1 & 1 & 2 & 0 & 0 & 0 \\ 0 & 1 & 1 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 1 & 1 & 0 & 0 & 0 \end{pmatrix}$$

	Social PageRank
doc: http://www.ted.com/	0.280676409730572
doc: http://www.colourlovers.com/	0.369220441236174
doc: http://www.behance.net/	0.384551423972747
usr: użytkownik A	0.402473669662513
usr: użytkownik B	0.354578057974890
tag: inspiration	0.383291185401107
tag: design	0.321455285546253
tag: portfolio	0.314739469615726

Zbierczość wektora została uzyskana po 22 iteracjach.

Patrząc na powyższe wyniki najwyższy ranking wśród dokumentów ma strona begence.net: została ona dodana przez 2 użytkowników i przypisane jej zostały 4 tagi. Niewiele niższy ranking ma witryna colourlovers dodana przez 2 użytkowników i opisana 2 różnymi anotacjami. Można po tym wnioskować że nadanie większej ilości tagów nie ma dużego wpływu na rank strony. Za to zmniejszenie liczby użytkowników którzy tą stronę dodali, ma duże: przykład strona ted.com i colourlovers.com gdzie widoczny jest dość duży skok wartości wyniku.

2.2 Implementacja

Z powodu długiego czasu działania i dużej ilości wymaganych danych nie mogą być one pobierane bezpośrednio z bazy danych. Przed rozpoczęciem działania algorytmu są one pobierane, zapisywane w struktury pozwalające na lepsze i szybsze ich przeglądanie i serializowane do pliku. Dodatkowo żeby przyspieszyć tworzenie danych korzystamy z dodatkowych tabel zawierających już wyliczone dane np: o ilości dokumentów dodanych i opisanych tym samym tagiem przez użytkowników.

W czasie każdej iteracji algorytmu są one pobierane z pliku, zamieniane na macierze i poddawane dalszym operacjom. Po zakończeniu działania algorytmu wyniki zapisywane są w bazie danych. Z powodu tego, że dane wymagane w algorytmie adapted pagerank są zbliżone do danych wymaganych w algorytmie socialpagerank wykorzystywane są te same zserializowane dane. Dokładniej macierz wygląda następująco:

$$G_f = \begin{pmatrix} 0 & M_{DU} & M_{TD}^T \\ M_{DU}^T & 0 & M_{UT} \\ M_{TD} & M_{UT}^T & 0 \end{pmatrix}$$

gdzie tworzenie macierzy M_{UD} , M_{TD} , M_{UT} jest opisana w rozdziale opisującym algorytm social page rank.

Dodatkowo podobnie jak w algorytmie socialPageRank z powodu wielkości macierzy i ograniczeń pamięciowych są one mnożone częściowo przez wektor wag.

2.3 Wyniki

// TODO: po zebraniu wystarczającej ilości danych
// opis kilku przykładowych dokumentów

2.4 Porównanie algorytmu SocialPageRank i algorytmu Adapted PageRank : TODO

2.4.1 Porównanie na małym przykładzie

Szybkość działania:

Zbieżność wektora uzyskano szybciej - bo już po pięciu iteracjach przy algorytmie SocialPageRank. W algorytmie Adapted Page Rank wymagało to aż 22 iteracji. Zbieżność można przyspieszać przez zmianę parametru α w algorytmie page rank.

Wyniki:

Kolejność wag dla dokumentów jest taka sama w przypadku jednego i drugiego algorytmu, ale ich wartości są zdecydowanie inne. W przypadku dokumentu o największej randze: behence.net i kolejnego colourlovers.com różnica dla algorytmu adapted page rank jest niewielka proporcjonalnie do wagi, a przy social page rank waga behence.net jest prawie dwa razy większa od poprzednika. Widoczne podobieństwo jest dopiero dla dokumentów colourlovers.com i ted.com gdzie różnica wyników algorytmów dla jednego i dokumentu jest znaczna. Jest to prawdopodobnie spowodowane, że na wynik jednego i drugiego algorytmu wpływa mała ilość użytkowników, którzy dodali dany dokument i mała ilość tagów przypisanych temu dokumentowi.

Dodatkowe dane:

Adapted Page Rank daje nam dodatkową wiedzę w postaci rank dla tagów i użytkowników. O ile nie jest to przydatne przy wyszukiwaniu, ale daje dodatkowe informacje o posiadanych danych.

2.4.2 Porównanie w działającym systemie

// TODO: zrobić po zebraniu dużej ilości danych
// wykresy ??
// porównanie i opis dla kilku dokumentów